

TECNOLOGIE DEI DATI E DEL LINGUAGGIO

Clusters to Lovers

Trope, TF-IDF e Sentiment Analysis nelle recensioni BookTok di Emily Henry

Zilan Polat

Prof. Alfio Ferrara — A.A. 2025/2026

Obiettivo e domanda di ricerca

È possibile, con strumenti di NLP relativamente semplici, riconoscere i trope romantici più discussi dai lettori e misurare in modo affidabile il loro sentiment?

Perché BookTok e Emily Henry?

Emily Henry è tra le autrici romance più discusse su BookTok: i suoi romanzi combinano più trope (enemies to lovers, second chance, fake dating...) in modo esplicito, rendendola un caso di studio ideale.

4

romanzi analizzati

270

recensioni sintetiche

5

trope romantici

Il dataset

270 recensioni sintetiche (positive, miste e negative): 18 recensioni-base ripetute 15 volte su 4 titoli

Beach Read

Book Lovers

Happy Place

Funny Story

Colonne principali del dataset

`review_text` — testo della recensione (inglese)

`ground_truth_trope` — trope di riferimento etichettato

`rating` — voto da 1 a 5

`book_title` — titolo del romanzo

Pipeline metodologica



Pre-processing e mappatura dei trope

Classificazione basata su regole (regex) su 5 categorie



Enemies to lovers

“enemies to lovers” · “hate to love” · “rivals”



Second chance

“second chance” · “exes” · “past relationship”



Fake dating

“fake dating” · “fake relationship” · “pretend”



Banter / Dialogue

“banter” · “witty” · “dialogue” · “funny” · “chemistry”





Emotional depth

“cried” · “emotional” · “heartbreaking” · “vulnerable”

TF-IDF e scelta di K

Metodo del Gomito e Silhouette Score per la clusterizzazione K-Means



Clustering K-Means

Raggruppamento delle recensioni nello spazio vettoriale TF-IDF ($K = 4$)

Cosa emerge

- Il cluster 2 coincide interamente con second chance; il cluster 0 è quasi tutto fake dating.
- Gli altri due cluster raggruppano più trope insieme (es. banter ed emotional depth): con 5 trope e $K = 4$ almeno due categorie devono confluire.
- Il clustering segue il lessico condiviso, non il tono: recensioni positive e negative dello stesso trope finiscono spesso insieme.

60

Cluster 0 recensioni

105

Cluster 1 recensioni

45

Cluster 2 recensioni

60

Cluster 3 recensioni

Sentiment Analysis (VADER) e Softmax

Punteggio di sentiment composito e distribuzione di probabilità a diverse temperature

0.89

correlazione di Pearson tra rating e sentiment VADER

Il tono lessicale segue il voto:

Il punteggio VADER cresce con il rating, anche sulle recensioni critiche. I trope sono invece quasi indipendenti dal sentiment (massimo $r = 0.22$, per second chance ed emotional depth). Nota: rating e tono sono coerenti per costruzione nel dataset.

Softmax con temperatura

Temperatura bassa ($t = 0.2$)


la distribuzione si concentra sul punteggio più alto: scelta quasi deterministica.

Temperatura alta ($t = 1.5$)

la distribuzione si appiattisce: più "casualità" tra le opzioni.

Valutazione: matrice di confusione

Trope predetto (regex) vs trope reale (ground truth)





Diagonale perfetta: perché?

Ogni recensione-base contiene la keyword del proprio trope (per emotional depth basta anche il trope di default quando nessuna keyword compare). La valutazione è quindi in parte circolare: l'accuratezza del 100% non dimostra che il metodo generalizzi a recensioni reali, dove le parole chiave attese potrebbero mancare o comparire ironia.

Parole distintive e correlazioni

Top 10 parole per TF-IDF e correlazione di Pearson tra rating, sentiment e trope



Limiti e bias dell'IA



Dataset sintetico

18 recensioni-base ripetute 15 volte, con rating coerente col tono per costruzione: non riflettono la variabilità reale di BookTok.



Valutazione circolare

Le keyword usate per predire il trope coincidono con quelle usate per scrivere le recensioni-base: l'accuratezza quasi perfetta non si generalizza a testi reali, ironici o ambigui.



VADER generico

Lessico non calibrato sul gergo BookTok (slang, emoji); rischio di misclassificare frasi come "cried" in contesti positivi.



Generalizzabilità limitata

I risultati non sono validati su un corpus di recensioni reali.

Conclusioni e prossimi passi

Cosa abbiamo imparato

- Le regole (regex) colgono bene i pattern lessicali espliciti, ma su questo dataset la valutazione è circolare.
- Il clustering non supervisionato segue il lessico condiviso più che la semantica dei trope o il tono.
- Il TF-IDF isola bene il lessico distintivo: emotional, lovers e romance sono le parole con il punteggio più alto.
- Il sentiment VADER correla fortemente con il rating ($r = 0.89$), i trope quasi per nulla (massimo $r = 0.22$).

Prossimi passi

- Validare la pipeline su un corpus reale di recensioni BookTok/Goodreads.
- Sostituire VADER con un modello di sentiment fine-tuned sul dominio.
- Esplorare classificazione multi-label dei trope invece del “primo trovato”.
- Confrontare K-Means con clustering gerarchico o basato su embedding.

Nota metodologica: il codice del notebook è stato scritto con il supporto di un assistente AI; impostazione del progetto, scelte metodologiche e analisi critica dei risultati sono a cura dell'autrice.